语言、自动机与正则表达式

2025 年秋冬学期计算机学院朋辈辅学计算理论

李克成

浙江大学

2025-11-02

语言

语言

- **符号集 Σ**：有限个符号组成的集合
- **字符串 w**：由符号集中符号组成的有限序列
  - 空串：e 或 ε
  - Σ^*：由 Σ 中符号组成的所有字符串的集合
  - Σ^+：由 Σ 中符号组成的非空字符串的集合
  - Σ^n：由 Σ 中符号组成的长度为 n 的字符串集合
  - 运算
    - 连接：$w_1 w_2$ 或 $w_1 \circ w_2$
    - 反转：w^R
    - 重复：w^k
    - 字符串长度：$|w|$

语言

- **语言 L**：字符串的集合，$L \subseteq \Sigma^*$
  - 空语言：$\emptyset$
  - 包含空串的语言：$\{\varepsilon\}$
  - 运算
    - 并集 $L_1 \cup L_2$，交集 $L_1 \cap L_2$，差集 $L_1 - L_2$
    - 连接：$L_1 L_2 = \{w_1 w_2 \mid w_1 \in L_1, w_2 \in L_2\}$
    - $L^* = L^0 \cup L^1 \cup L^2 \cup \ldots$
    - $L^+ = LL^*$

有限自动机（FA）

确定性有限自动机（DFA）

- 五元组 $M = (K, \Sigma, \delta, s, F)$
  - K：有限状态集合
  - Σ：输入符号集
  - $\delta : K \times \Sigma \to K$：状态转移函数
  - $s \in K$：初始状态
  - $F \subseteq K$：接受状态集合
- 配置：(q, w)，$q \in K$，$w \in \Sigma^*$
  - $(q, aw) \vdash_M (q', w)$：一步转移
  - $(q, w) \vdash_M^* (q', w')$：若干步转移
  - $(s, w) \vdash_M^* (q, e), q \in F$：接受字符串 w
- $L(M)$：自动机 M 接受的字符串形成的语言

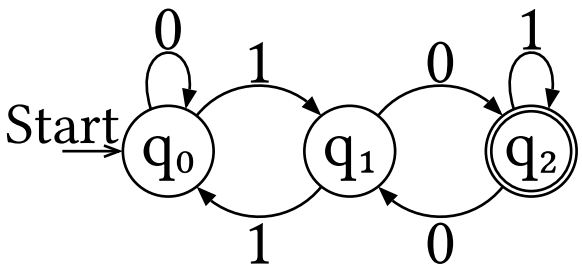

DFA 最小化

- 任意能被 DFA 表示的语言都存在唯一的最小化 DFA
- 最小化 DFA
  - 删除不可达状态
  - 合并等价状态：将状态划分为若干等价类
    - 接受状态与非接受状态不等价
    - 对某一输入符号转移到不同等价类的两个状态不等价
- 从 $\{K - F, F\}$ 开始，不断细分每个暂定的等价类直到无法细分

DFA 最小化

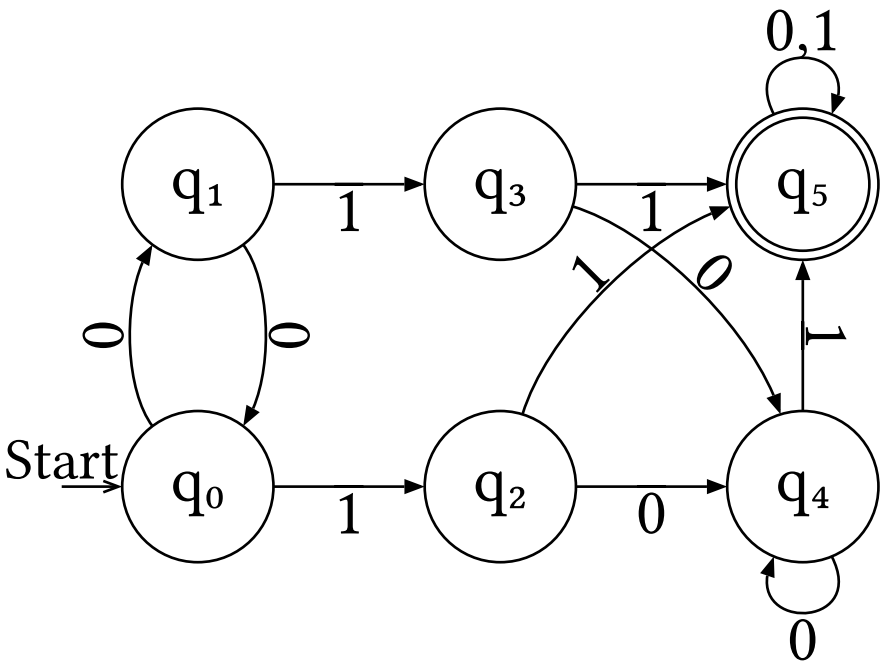

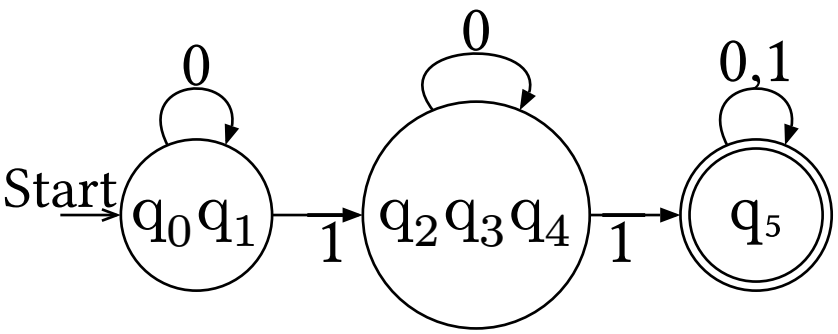

- 初始：$\{q_0, q_1, q_2, q_3, q_4\}, \{q_5\}$
- $\{q_0, q_1\}, \{q_2, q_3, q_4\}, \{q_5\}$

非确定性有限自动机（NFA）

- 五元组 $M = (K, \Sigma, \Delta, s, F)$
  - K：有限状态集合
  - Σ：输入符号集
  - $\Delta : K \times (\Sigma \cup \{\varepsilon\})$：状态转移集合
  - $s \in K$：初始状态
  - $F \subseteq K$：接受状态集合
- 存在一种转移路线接受字符串 w 即称为 NFA 接受字符串 w

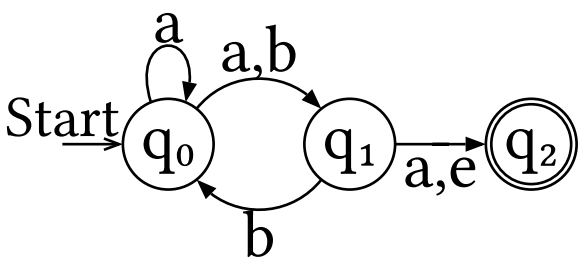

NFA 到 DFA 的转换

- 所有 DFA 都是 NFA
- NFA 可以通过子集构造法转换为等价的 DFA
  - 用 DFA 的状态表示 NFA 状态的子集
    - ε-闭包 $E(q) = \{p \in K : (q, e) \vdash_M^* (p, e)\}$
    - 初始状态为 NFA 初始状态的 ε-闭包
    - 接受状态为包含 NFA 接受状态的子集
  - 通常使用 BFS 方法遍历所有需要的状态

NFA 到 DFA 的转换

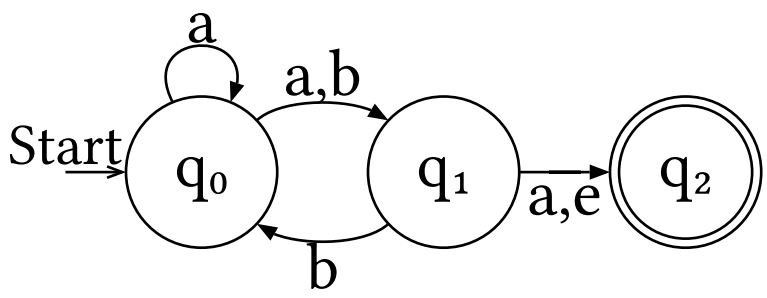

ID	States	a	b
0	q_0	1	2
1	q_0, q_1, q_2	1	1
2	q_1, q_2	3	1
3	q_2		

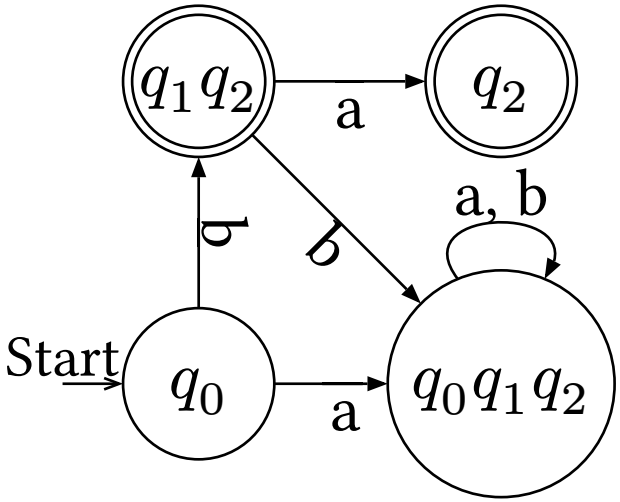

正则表达式和正则语言

正则表达式（Regular Expression）

- $\Sigma \cup \{(,), \cup, *, \emptyset\}$ 上的字符串
  - $\emptyset$ 是正则表达式，对应语言 $L(\emptyset) = \emptyset$
  - $\forall a \in \Sigma$，a 是正则表达式，对应语言 $L(a) = \{a\}$
  - 如果 r_1 和 r_2 是正则表达式，则
    - $(r_1 \cup r_2)$ 是正则表达式，对应语言 $L(r_1) \cup L(r_2)$
    - $(r_1 r_2)$ 是正则表达式，对应语言 $L(r_1) \circ L(r_2)$
    - (r_1^*) 是正则表达式，对应语言 $L(r_1)^*$
    - 运算优先级：$* > \circ > \cup$
  - 不符合以上规则的字符串不是正则表达式
  - 所有正则表达式的集合：$\mathcal{R}$

从正则表达式构造 NFA

- 已知 NFA $M_1 = (K_1, \Sigma, \Delta_1, s_1, F_1)$ 和 $M_2 = (K_2, \Sigma, \Delta_2, s_2, F_2)$
  - 构造 $L(M) = L(M_1) \cup L(M_2)$
    - $K = K_1 \cup K_2 \cup \{s\}, F = F_1 \cup F_2$
    - $\Delta = \Delta_1 \cup \Delta_2 \cup \{(s, e, s_1), (s, e, s_2)\}$
  - 构造 $L(M) = L(M_1) \circ L(M_2)$
    - $K = K_1 \cup K_2, F = F_2$
    - $\Delta = \Delta_1 \cup \Delta_2 \cup \{(q, e, s_2) : q \in F_1\}$
  - 构造 $L(M) = L(M_1)^*$
    - $K = K_1 \cup \{s\}, F = F_1 \cup \{s\}$
    - $\Delta = \Delta_1 \cup \{(s, e, s_1)\} \cup \{(q, e, s_1) : q \in F_1\}$
    - 构造新的初始状态是有必要的：空串或中途返回起始状态

从 NFA 构造正则表达式

- 广义 NFA $M_G = (K_G, \Sigma_G, \Delta_G, s_G, F_G)$
  - 仅有一个接受状态 $F = \{f_G\}$
  - $\Sigma_G = \Sigma \cup \mathcal{R}_0$，$\mathcal{R}_0$ 是有限的正则表达式集合（边上可以使用正则表达式）
  - $\Delta_G \subseteq (K - f_G) \times (\Sigma \cup \{e\} \cup \mathcal{R}_0) \times (K - s_G)$
- 从 NFA 构造广义 NFA：添加新初始状态 s_G 和接受状态 f_G
- 消除状态 $q \in K_G - \{s_G, f_G\}$：
  - 对于每对状态 (p, r)，若存在转移 $(p, a_1, q), (q, a_2, r)$
    - 如果 q 有自环 (q, a_3, q)，则添加转移 $(p, (a_1(a_3)^* a_2), r)$
    - 否则添加转移 $(p, (a_1 a_2), r)$
  - 删除状态 q 及其相关转移

正则语言（Regular Language）

- 可由某个正则表达式表示的语言称为正则语言
- L 是正则语言 $\leftrightarrow$ L 可由某个 FA 接受
- 闭包性质：当 A 和 B 是正则语言时：
  - $A \cup B = \{w : w \in A \text{ or } w \in B\}$ 是正则的
  - $A \circ B = \{w_1 w_2 : w_1 \in A, w_2 \in B\}$ 是正则的
  - $A^* = \{w_1 w_2 ... w_k : k \geq 0, w_i \in A\}$ 是正则的
  - $\overline{A} = \Sigma^* - A$ 是正则的
  - $A^R = \{w^R : w \in A\}$ 是正则的
  - $A \cap B = \{w : w \in A, w \in B\} = \overline{\overline{A} \cup \overline{B}}$ 是正则的
  - $A - B = \{w : w \in A, w \notin B\} = A \cap \overline{B}$ 是正则的
  - 令 $h : \Sigma \to \Gamma^*$，将其扩展为 $h : \Sigma^* \to \Gamma^*$，其中 $h(e) = e$，$h(a_1 a_2 ... a_n) = h(a_1)h(a_2)...h(a_n)$
    - $C_1 = \{h(w) : w \in A\}, C_2 = \{h^{-1}(w) : w \in A\}$ 是正则的
  - 无限次运算后不一定是正则的

Pumping Theorem

$$\forall L \subseteq \Sigma^*, \text{regular}(L) \rightarrow$$
$$(\exists p \geq 1, \forall w \in L, |w| \geq p \rightarrow$$
$$\exists x, y, z \in \Sigma^*, (w = xyz) \wedge (|xy| \leq p) \wedge (|y| \geq 1) \wedge (\forall i \geq 0, xy^i z \in L))$$

证明:

- 令 $M = (K, \Sigma, \delta, s, F)$ 是接受语言 L 的 DFA，取 $p = |K|$
- 输入长度不小于 p 的字符串 $w \in L$，则在 M 处理 w 的前 p 步过程中经过了 $p + 1$ 个状态，必然有某个状态 q_s 被访问了至少两次
- 令 y 为两次访问 q_s 之间读取的字符串，x 为之前读取的字符串，z 为之后读取的字符串

Pumping Theorem

- 变形:

$$\forall L \subseteq \Sigma^*,$$
$$(\forall p \geq 1, \exists w \in L, |w| \geq p \wedge (\forall x, y, z \in \Sigma^*,$$
$$(w = xyz) \wedge (|xy| \leq p) \wedge (|y| \geq 1) \rightarrow (\exists i \geq 0, xy^i z \notin L)))$$
$$\rightarrow \neg \text{ regular}(L)$$

- 例：语言 $L = \{a^n b^n \mid n \geq 0\}$
  - 对于所有 $p \geq 1$，取 $w = a^p b^p \in L$，则 $|w| = 2p \geq p$
  - 任意划分 $w = xyz$ 使 $|xy| \leq p, |y| \geq 1$，则 $y = a^k, k \geq 1$
  - 取 $i = 0$，则 $xy^i z = a^{p-k} b^p \notin L$
  - 因此 L 不是正则语言

正则语言的判定

- 不存在判断任意语言是否正则的通用方法
- 证明语言正则
  - 该语言有限
  - 构造一个接受该语言的 FA
  - 构造一个生成该语言的正则表达式
  - 正则语言的闭包性质
- 证明语言非正则
  - Pumping Theorem
  - 反证
    - 不存在接受该语言的 FA
    - 正则语言的闭包性质

正则语言的判定

例 1 $L = \{a^i b^j c^k : i + j \not\equiv k \pmod 3, i, j, k \in \mathbb{N}\}$

正则语言的判定

例 1 $L = \{a^i b^j c^k : i + j \not\equiv k \pmod 3, i, j, k \in \mathbb{N}\}$

令 $i \equiv t_1 \pmod 3, j \equiv t_2 \pmod 3, k \equiv t_3 \pmod 3, t_1, t_2, t_3 \in \{0, 1, 2\}$

显然 (t_1, t_2, t_3) 的取值只有有限种

正则语言的判定

例 1 $L = \{a^i b^j c^k : i + j \not\equiv k \pmod 3, i, j, k \in \mathbb{N}\}$

令 $i \equiv t_1 \pmod 3, j \equiv t_2 \pmod 3, k \equiv t_3 \pmod 3, t_1, t_2, t_3 \in \{0, 1, 2\}$

显然 (t_1, t_2, t_3) 的取值只有有限种

$L_{1,t_1} = \{a^{3n_1+t_1} : n_1 \in \mathbb{N}\}, L_{2,t_2} = \{b^{3n_2+t_2} : n_2 \in \mathbb{N}\}, L_{3,t_3} = \{c^{3n_3+t_3} : n_3 \in \mathbb{N}\}$ 均为正则语言

对每组 (t_1, t_2, t_3) 的取值，$L_{1,t_1} \circ L_{2,t_2} \circ L_{3,t_3}$ 为正则语言

正则语言的判定

例 1 $L = \{a^i b^j c^k : i + j \not\equiv k \pmod 3, i, j, k \in \mathbb{N}\}$

令 $i \equiv t_1 \pmod 3, j \equiv t_2 \pmod 3, k \equiv t_3 \pmod 3, t_1, t_2, t_3 \in \{0, 1, 2\}$

显然 (t_1, t_2, t_3) 的取值只有有限种

$L_{1,t_1} = \{a^{3n_1+t_1} : n_1 \in \mathbb{N}\}, L_{2,t_2} = \{b^{3n_2+t_2} : n_2 \in \mathbb{N}\}, L_{3,t_3} = \{c^{3n_3+t_3} : n_3 \in \mathbb{N}\}$ 均为正则语言

对每组 (t_1, t_2, t_3) 的取值，$L_{1,t_1} \circ L_{2,t_2} \circ L_{3,t_3}$ 为正则语言

$L = \bigcup_{t_1+t_2 \not\equiv t_3 \pmod 3} L_{1,t_1} \circ L_{2,t_2} \circ L_{3,t_3}$ 为有限个正则语言的并集，故 L 为正则语言

正则语言的判定

例 2 $L = \{w : w \text{ is binary representation of } n, n \bmod 3 = 0, n \in \mathbb{N}\}$

正则语言的判定

例 2 $L = \{w : w \text{ is binary representation of } n, n \bmod 3 = 0, n \in \mathbb{N}\}$

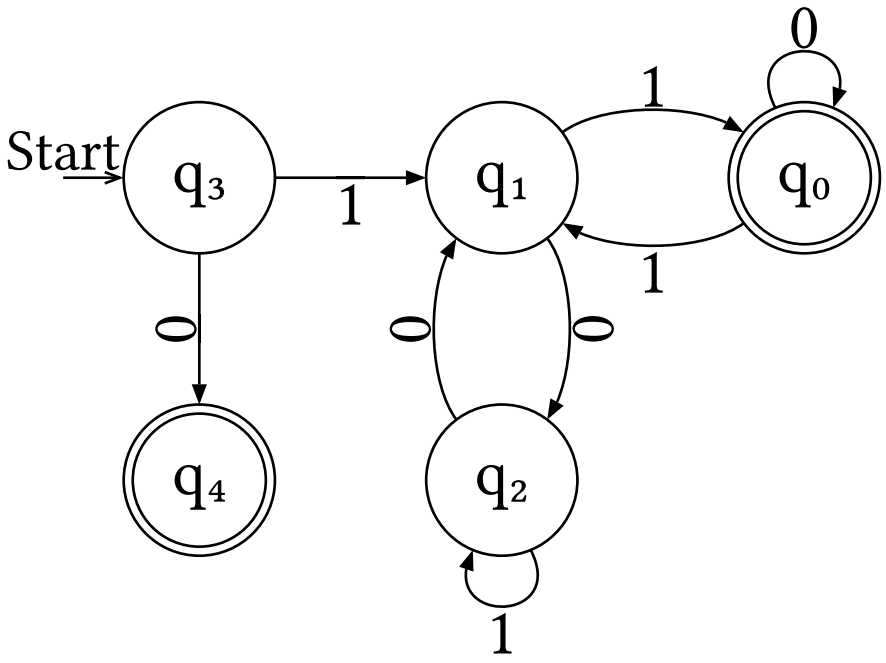

正则语言的判定

例 3 $L = \{w : w \in \{a, b\}^*, w \neq w^R\}$

正则语言的判定

例 3 $L = \{w : w \in \{a, b\}^*, w \neq w^R\}$

令 $L' = \{a, b\}^* - L = \{w : w \in \{a, b\}^*, w = w^R\}$

则 L 和 L' 的正则性相同

正则语言的判定

例 3 $L = \{w : w \in \{a,b\}^*, w \neq w^R\}$

令 $L' = \{a,b\}^* - L = \{w : w \in \{a,b\}^*, w = w^R\}$

则 L 和 L' 的正则性相同

- 对任意 $p \geq 1$，取 $w = a^p b a^p \in L'$，则 $|w| = 2p + 1 \geq p$
- 任意划分 $w = xyz$ 使 $|xy| \leq p, |y| \geq 1$，则 $y = a^k, k \geq 1$
- 取 $i = 0$，则 $xy^iz = a^{p-k} b a^p \notin L'$
- 因此 L' 不是正则语言，故 L 也不是正则语言